Universidad del Valle de Guatemala

Facultad de Ingeniería

Catedrático: Alan Reyes

Seccion: 20

Inteligencia Artificial — 2026

Proyecto 1

Predicción de Tarifas de Transporte en NYC

Integrantes

Joel Jaquez	`Carné: 23369`
Diego Patzan	`Carné: 23525`
Luis Gonzalez	`Carné: 23353`

Guatemala, 6 de abril de 2026

Índice

1. Introducción **3**

2. Presentación de los Datos **3**
2.1. Descripción del Dataset . . . 3
2.2. Análisis de Valores Faltantes . . . 4
2.3. Análisis Exploratorio y Detección de Outliers . . . 4

3. Limpieza de Datos **5**
3.1. Técnicas Aplicadas . . . 5
3.2. Resultado de la Limpieza . . . 6

4. Ingeniería de Características **7**
4.1. Distancia Haversine . . . 7
4.2. Variables Temporales . . . 8
4.3. Zonas de Interés — Aeropuertos . . . 8

5. Partición Train/Test **9**

6. Experimentación con Modelos **9**
6.1. Regresión Lineal Multivariada . . . 9
6.1.1. Descripción del Modelo . . . 9
6.1.2. Parámetros e Hiperparámetros . . . 10
6.1.3. Métricas de Evaluación . . . 11
6.1.4. Visualización de Resultados . . . 11
6.1.5. Limitaciones . . . 12
6.2. Random Forest . . . 12
6.2.1. Descripción del Modelo . . . 12
6.2.2. Búsqueda de Hiperparámetros . . . 12
6.2.3. Métricas de Evaluación . . . 13
6.2.4. Importancia de Variables . . . 13
6.2.5. Visualización de Resultados . . . 15
6.2.6. Análisis de Puntos de Alta Influencia . . . 16
6.2.7. Limitaciones . . . 16
6.3. Red Neuronal Densa (MLP) . . . 16
6.3.1. Descripción del Modelo . . . 16
6.3.2. Búsqueda de Hiperparámetros . . . 16
6.3.3. Arquitectura del Modelo . . . 17
6.3.4. Métricas de Evaluación . . . 18
6.3.5. Visualización de Resultados . . . 18
6.3.6. Análisis de Puntos de Alta Influencia . . . 19
6.3.7. Limitaciones . . . 20

7. Prueba de Usuario **20**

8. Comparación de Resultados **21**

9. Conclusiones **22**

1. Introducción

El presente documento corresponde al Primer Proyecto del curso de Inteligencia Artificial 2026, en el cual se aborda el desarrollo de un agente reactivo basado en modelos de machine learning supervisado para regresión.

Se eligió la Opción A: Predicción de Tarifas de Transporte en NYC, cuyo objetivo es construir un modelo predictivo capaz de estimar el costo de un viaje en taxi en la ciudad de Nueva York, dadas las coordenadas geográficas de origen y destino, la fecha, la hora y el número de pasajeros.

El dataset utilizado proviene de la competencia pública de Kaggle New York City Taxi Fare Prediction, el cual contiene aproximadamente 55 millones de registros históricos de viajes en taxi. Dado el volumen de datos, se trabajó con una muestra representativa de 1,000,000 de filas, cargadas mediante el parámetro nrows de la función pandas.read_csv().

El proyecto cubre las siguientes fases:

1. Análisis Exploratorio de Datos y Limpieza
2. Ingeniería de Características (Feature Engineering)
3. Partición del conjunto de datos en entrenamiento y prueba
4. Experimentación y comparación de modelos de regresión

2. Presentación de los Datos

2.1. Descripción del Dataset

El dataset contiene registros de viajes en taxi en Nueva York, con las siguientes variables:

Cuadro 1: Descripción de variables del dataset

Variable	**Tipo**	**Descripción**
`key`	string	Identificador único del viaje
`pickup_datetime`	timestamp	Fecha y hora de inicio del viaje
`pickup_longitude`	float64	Longitud del punto de origen
`pickup_latitude`	float64	Latitud del punto de origen
`dropoff_longitude`	float64	Longitud del punto de destino
`dropoff_latitude`	float64	Latitud del punto de destino
`passenger_count`	int64	Número de pasajeros
`fare_amount`	float64	**Target:** Costo del viaje en USD

2.2. Análisis de Valores Faltantes

Al cargar la muestra de 1,000,000 de filas se identificaron valores nulos únicamente en las variables de coordenadas de destino, tal como se muestra a continuación:

Cuadro 2: Valores nulos por variable

Variable	**Nulos**	**Porcentaje (%)**
`key`	0	0.00
`fare_amount`	0	0.00
`pickup_datetime`	0	0.00
`pickup_longitude`	0	0.00
`pickup_latitude`	0	0.00
`dropoff_longitude`	10	0.00
`dropoff_latitude`	10	0.00
`passenger_count`	0	0.00

Los 10 registros con valores nulos representan menos del 0.001 % del dataset, por lo que fueron eliminados directamente sin necesidad de técnicas de imputación.

2.3. Análisis Exploratorio y Detección de Outliers

Antes de proceder con la limpieza, se analizaron las distribuciones de cada variable para identificar valores atípicos. Las distribuciones iniciales evidenciaron la presencia de datos claramente erróneos:

- `fare_amount`: valores negativos (mínimo de $-44.90) y valores extremadamente altos ($500).
- Coordenadas geográficas: longitudes y latitudes fuera de cualquier rango real (hasta -3,377 y 2,621 respectivamente), indicando registros corruptos.
- `passenger_count`: valores de 0 y hasta 208 pasajeros, ambos imposibles para un taxi convencional.

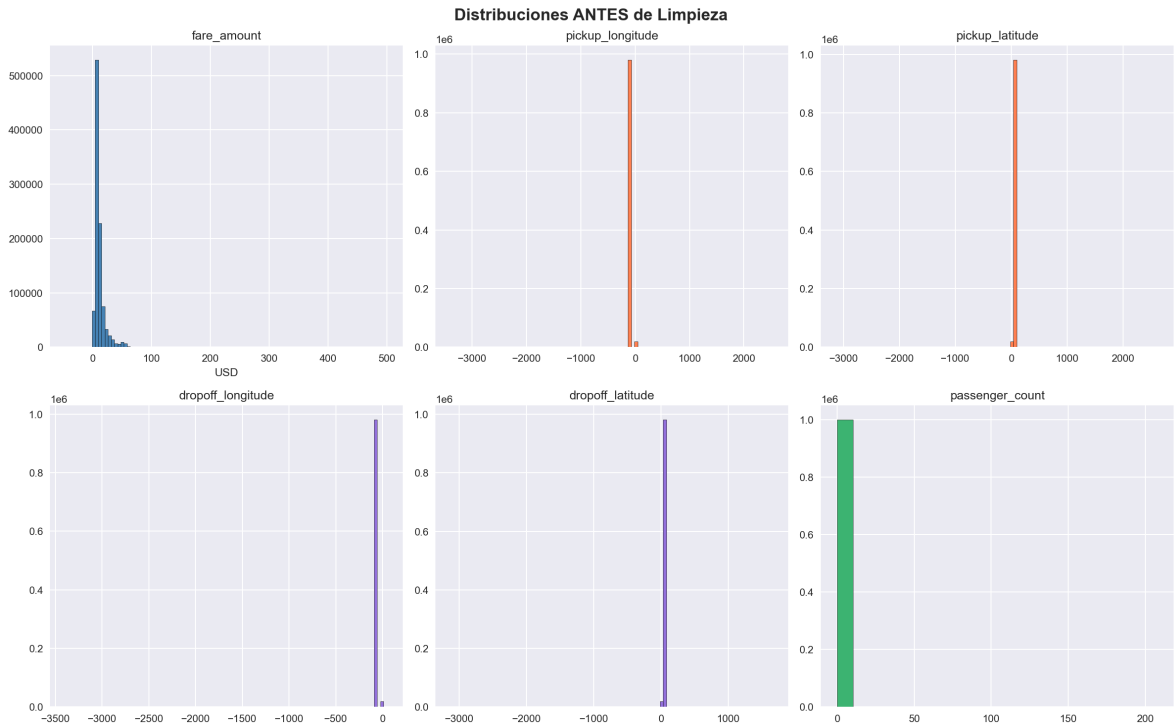

Figura 1: Distribuciones de variables antes de la limpieza. Se observan outliers extremos en coordenadas y pasajeros.

3. Limpieza de Datos

3.1. Técnicas Aplicadas

Con base en el análisis exploratorio, se aplicaron los siguientes filtros de limpieza:

1. **Eliminación de nulos:** Se eliminaron los 10 registros con valores faltantes en las coordenadas de destino.

2. **Limpieza de etiquetas:** Se eliminaron viajes con `fare_amount` ≤ 0 (tarifas negativas o gratuitas) y mayores a \$200 (valores atípicos extremos).

3. **Limpieza geográfica:** Se definió un *bounding box* correspondiente a la zona metropolitana de Nueva York y se eliminaron todos los registros fuera de este rango:

$$\text{Latitud} \in [40{,}4774,\ 41{,}0755]$$
$$\text{Longitud} \in [-74{,}2591,\ -71{,}6966]$$

4. **Limpieza de pasajeros:** Se conservaron únicamente viajes con `passenger_count` entre 1 y 7, que corresponde a la capacidad real de un taxi en NYC.

5. **Filtro de distancias:** Posterior al cálculo de la distancia Haversine, se eliminaron viajes con distancia igual a 0 km (origen igual a destino) y mayores a 100 km.

3.2. Resultado de la Limpieza

Cuadro 3: Resumen del proceso de limpieza

Etapa	**Filas restantes**
Dataset inicial	1,000,000
Tras eliminar nulos	999,990
Tras limpiar fare_amount	999,885
Tras limpieza geográfica	978,475
Tras limpiar pasajeros	974,993
Tras filtrar distancias	964,769

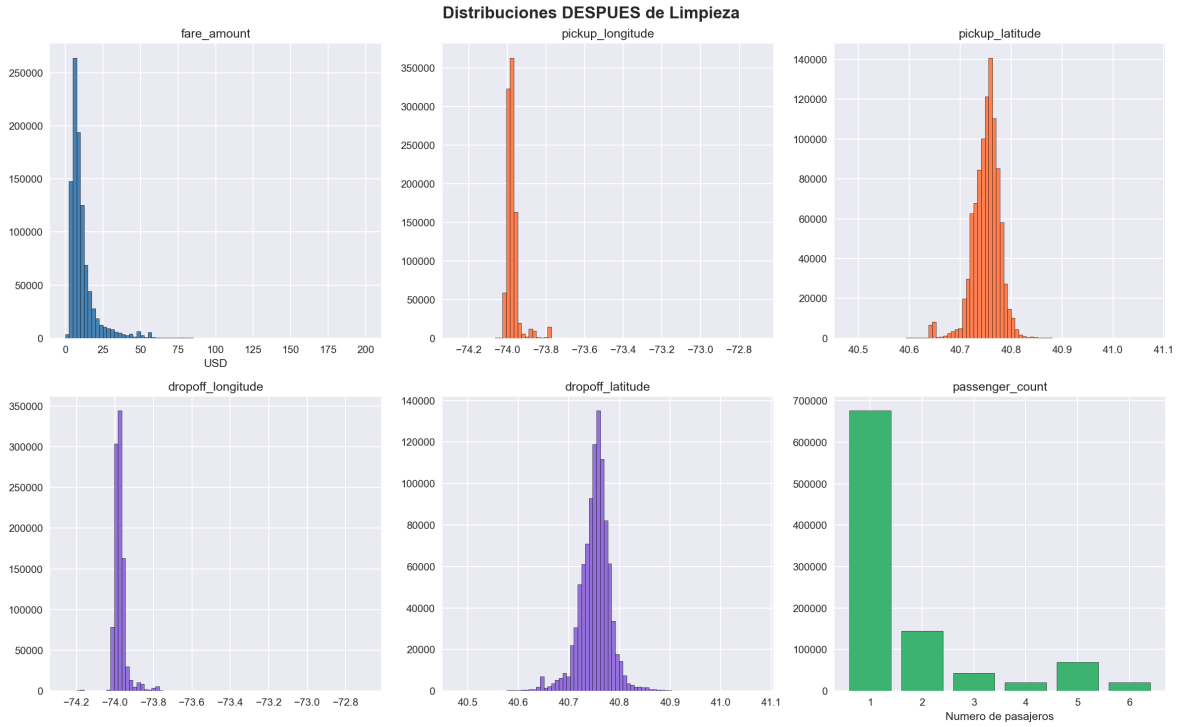

Figura 2: Distribuciones de variables después de la limpieza. Las coordenadas ahora están concentradas en la zona de NYC y las tarifas muestran una distribución coherente.

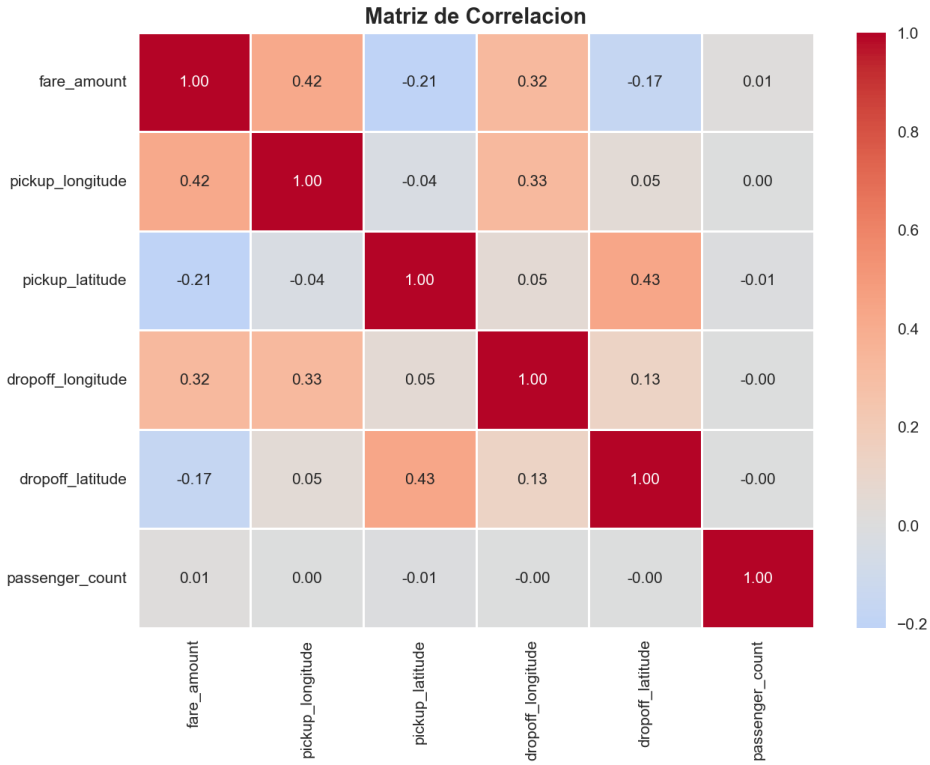

Figura 3: Matriz de correlación entre variables numéricas. Se destaca la correlación de 0.42 entre `pickup_longitude` y `fare_amount`.

4. Ingeniería de Características

4.1. Distancia Haversine

Dado que las coordenadas geográficas por sí solas no representan directamente la distancia recorrida, se implementó la **Fórmula de Haversine** para calcular la distancia circular (en km) entre el punto de origen y el punto de destino de cada viaje:

$$d = 2R \cdot \arcsin\left(\sqrt{\sin^2\left(\frac{\Delta\phi}{2}\right) + \cos\phi_1 \cdot \cos\phi_2 \cdot \sin^2\left(\frac{\Delta\lambda}{2}\right)}\right) \tag{1}$$

donde $R = 6{,}371$ km es el radio de la Tierra, ϕ representa la latitud y λ la longitud de cada punto.

Los resultados obtenidos al aplicar la fórmula sobre el dataset limpio muestran distancias coherentes con la geografía de Nueva York:

Cuadro 4: Estadísticas descriptivas de la distancia calculada

Estadístico	**Valor (km)**
Media	3.32
Mediana	2.15
Desv. estándar	3.58
Mínimo	0.00
Máximo	107.14

Estos valores son coherentes con la dinámica de transporte en Nueva York: el 50 % de los viajes recorre menos de 2.15 km, lo que refleja el uso frecuente del taxi para trayectos cortos dentro de Manhattan. La distancia promedio de 3.32 km confirma que la mayoría de viajes son de corta duración, mientras que el valor máximo corresponde a viajes ocasionales hacia aeropuertos u otras zonas alejadas del centro.

4.2. Variables Temporales

Del campo `pickup_datetime` se extrajeron las siguientes variables para capturar patrones temporales en la demanda y precio:

- `hour`: hora del día (0–23)
- `day_of_week`: día de la semana (0=Lunes, 6=Domingo)
- `month`: mes del año (1–12)
- `year`: año del viaje

4.3. Zonas de Interés — Aeropuertos

Se crearon variables binarias que indican si el origen o destino del viaje se encuentra dentro del radio de los tres aeropuertos principales de Nueva York: JFK, LaGuardia y Newark. Esto es relevante porque los viajes a aeropuertos suelen tener tarifas fijas o significativamente más altas.

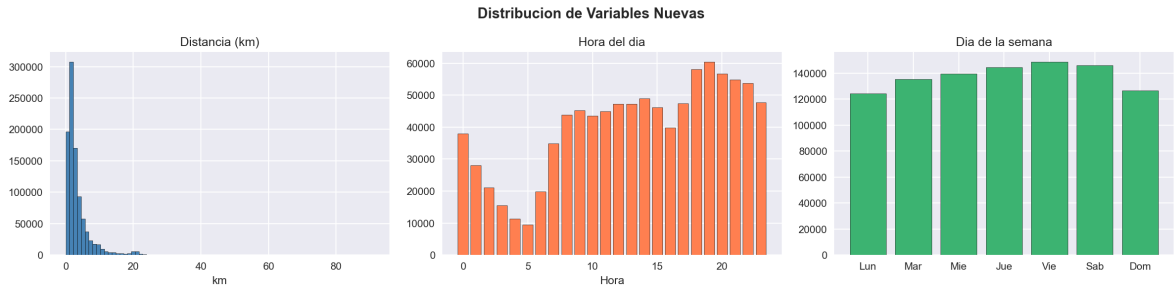

Figura 4: Distribución de las variables creadas: distancia en km, hora del día y día de la semana.

5. Partición Train/Test

El dataset limpio de 964,769 registros fue dividido en dos conjuntos utilizando la función train_test_split de la librería scikit-learn, con una proporción de 80 % para entrenamiento y 20 % para prueba:

Cuadro 5: Resultado de la partición train/test

Conjunto	**Filas**	**Proporción**
Entrenamiento (train)	771,815	80 %
Prueba (test)	192,954	20 %
Total	**964,769**	**100 %**

Se utilizó random_state=42 para garantizar la reproducibilidad de la partición. El conjunto de prueba no fue utilizado en ninguna etapa del entrenamiento, preservando su función como evaluador imparcial del desempeño final de los modelos.

Las 16 variables utilizadas como features de entrada son: `distance_km`, `hour`, `day_of_week`, `month`, `year`, `passenger_count`, `pickup_longitude`, `pickup_latitude`, `dropoff_longitude`, `dropoff_latitude`, `pickup_jfk`, `pickup_laguardia`, `pickup_newark`, `dropoff_jfk`, `dropoff_laguardia` y `dropoff_newark`.

6. Experimentación con Modelos

En esta sección se presentan los modelos entrenados para predecir la tarifa de los viajes en taxi. Todos los modelos fueron entrenados desde cero utilizando únicamente los datos preparados en las fases anteriores, sin uso de modelos pre-entrenados.

6.1. Regresión Lineal Multivariada

6.1.1. Descripción del Modelo

La Regresión Lineal Multivariada es el modelo base del proyecto. Busca encontrar una relación lineal entre las variables de entrada y la tarifa, ajustando una ecuación de la forma:

$$\hat{y} = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_n x_n \tag{2}$$

donde $\hat{y}$ es la tarifa predicha, β_0 es el intercepto y $\beta_1, \ldots, \beta_n$ son los coeficientes aprendidos para cada una de las 16 variables de entrada.

6.1.2. Parámetros e Hiperparámetros

La Regresión Lineal no requiere ajuste de hiperparámetros, ya que su solución es analítica y cerrada. Los parámetros aprendidos durante el entrenamiento son los coeficientes β de cada variable. El modelo fue entrenado en 0.11 segundos, lo que lo convierte en la opción más eficiente computacionalmente.

El intercepto aprendido fue $\beta_0 = -238{,}82$. Los coeficientes más relevantes se presentan en la siguiente tabla:

Cuadro 6: Coeficientes del modelo de Regresión Lineal

Variable	**Coeficiente**
`dropoff_newark`	28.5348
`pickup_newark`	22.2966
`pickup_longitude`	8.3696
`dropoff_laguardia`	5.5323
`pickup_laguardia`	4.7180
`dropoff_jfk`	4.1845
`pickup_jfk`	2.4906
`distance_km`	2.0804
`pickup_latitude`	1.4895
`year`	0.5215
`month`	0.0697
`passenger_count`	0.0298
`hour`	0.0100
`day_of_week`	-0.0377
`dropoff_longitude`	-2.4476
`dropoff_latitude`	-10.5370

Los coeficientes más altos corresponden a las variables de aeropuertos, especialmente Newark, lo cual es coherente con la realidad porque los viajes hacia o desde ese aeropuerto tienen tarifas significativamente más altas por ser el más lejano del centro de Manhattan. La variable distance_km tiene un coeficiente de 2.08, lo que indica que por cada kilómetro adicional la tarifa aumenta aproximadamente $2.08. Variables como hour, month y passenger_count tienen coeficientes cercanos a cero, confirmando que su influencia en la tarifa es mínima.

6.1.3. Métricas de Evaluación

Cuadro 7: Métricas de desempeño — Regresión Lineal

Conjunto	MAE	RMSE	R^2
Train	2.1444	4.2039	0.8049
Test	2.1469	4.2267	0.8017

El modelo obtuvo un R^2 de 0.80, lo que indica que explica el 80 % de la variabilidad en las tarifas. El error absoluto medio (MAE) de \$2.14 significa que en promedio el modelo se equivoca \$2.14 dólares por viaje. La diferencia mínima entre las métricas de train y test confirma que no existe overfitting.

6.1.4. Visualización de Resultados

Figura 5: Regresión Lineal: Predicciones vs Valores Reales. Los puntos cercanos a la línea roja indican predicciones precisas.

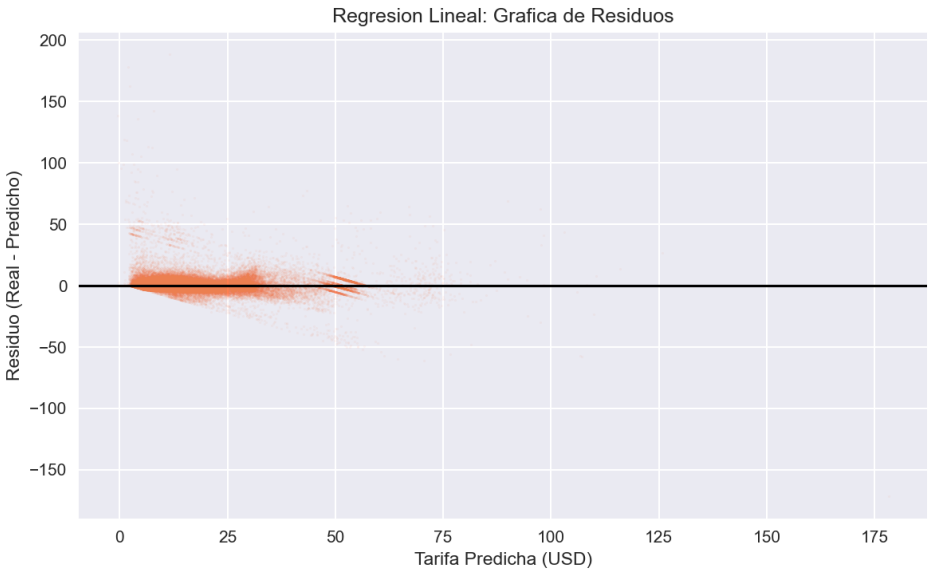

Figura 6: Regresión Lineal: Gráfica de Residuos. Se observa un patrón de heterocedasticidad, osea que los errores aumentan para tarifas más altas, además indica que el modelo tiene dificultades para capturar relaciones no lineales.

6.1.5. Limitaciones

La principal limitación observada es la heterocedasticidad en los residuos, es decir que el modelo predice bien los viajes cortos y baratos, pero subestima tarifas altas y no captura adecuadamente las tarifas fijas de los aeropuertos, con esto se puede afirmar que un modelo capaz de capturar relaciones no lineales podría obtener mejores resultados.

6.2. Random Forest

6.2.1. Descripción del Modelo

Random Forest es un modelo de ensamble basado en árboles de decisión. Durante el entrenamiento se construyen múltiples árboles independientes, cada uno entrenado con una muestra aleatoria del dataset y un subconjunto aleatorio de variables, la predicción final es el promedio de las predicciones individuales de todos los árboles.

Se eligió como segundo modelo por su capacidad de capturar relaciones no lineales entre las variables, lo cual aborda directamente la limitación de heterocedasticidad detectada en la Regresión Lineal, tambien, no requiere normalización de los datos y ofrece una medida directa de importancia de cada variable.

6.2.2. Búsqueda de Hiperparámetros

Se utilizó `GridSearchCV` con validación cruzada de 3 *folds* sobre una submuestra de 100,000 filas del conjunto de entrenamiento para optimizar el tiempo de cómputo, la métrica de optimización fue el MAE (*Mean Absolute Error*). El proceso de búsqueda tomó 320.7 segundos.

Cuadro 8: Espacio de búsqueda de hiperparámetros — Random Forest

Hiperparámetro	**Valores probados**
`n_estimators`	100, 200
`max_depth`	15, 20, None
`min_samples_split`	5, 10

Se evaluaron 12 combinaciones en total (36 *fits*). La mejor configuración encontrada fue:

Cuadro 9: Mejores hiperparámetros encontrados

Hiperparámetro	**Valor óptimo**
`n_estimators`	200
`max_depth`	None (sin límite)
`min_samples_split`	10

El mejor MAE obtenido durante la validación cruzada fue de \$1.8245, el modelo final fue re-entrenado con estos hiperparámetros sobre el conjunto de entrenamiento completo (771,815 filas).

6.2.3. Métricas de Evaluación

A continuación se presentan los resultados obtenidos tras evaluar el modelo en ambos conjuntos:

Cuadro 10: Métricas de desempeño — Random Forest

Conjunto	**MAE**	**RMSE**	$\mathbf{R^2}$
Train	0.9196	1.9957	0.9560
Test	1.6436	3.4233	0.8699

Random Forest obtuvo un R^2 de 0.87 en el conjunto de prueba, lo que representa una mejora de 7 puntos porcentuales respecto a la Regresión Lineal (0.80). El MAE de \$1.64 implica una reducción del 23 % en el error promedio, pero la diferencia entre el R^2 de entrenamiento (0.956) y el de prueba (0.870) sugiere un grado de *overfitting* que debe ser considerado.

6.2.4. Importancia de Variables

Una ventaja de este modelo es la capacidad de cuantificar la importancia relativa de cada *feature*, los resultados confirman que la distancia es el factor determinante:

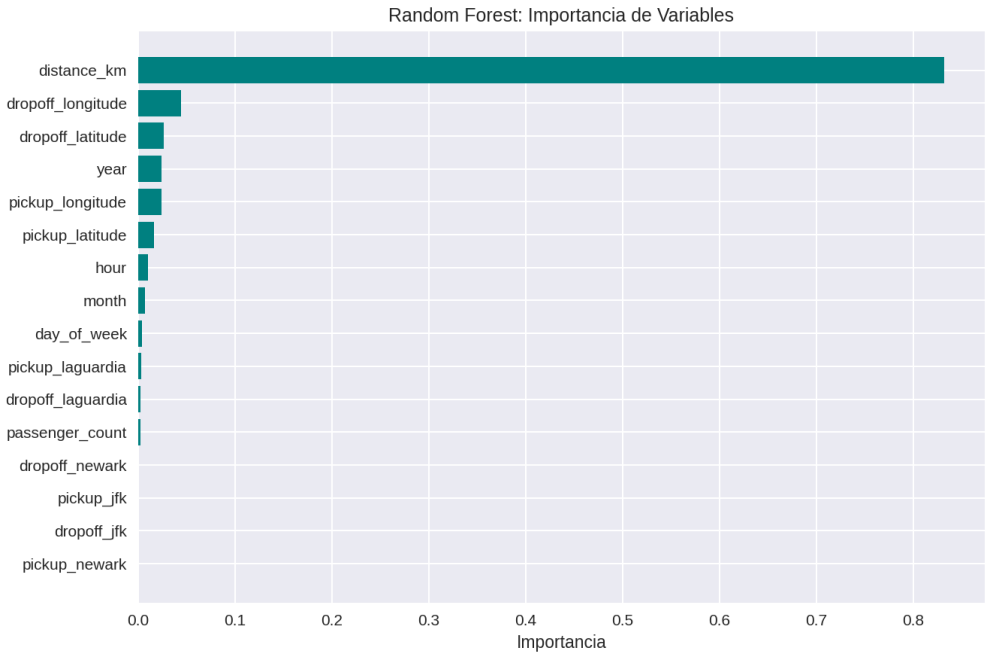

Figura 7: Importancia de variables. La variable `distance_km` domina la predicción con un 83 %, mientras que las variables binarias de aeropuertos tienen un impacto marginal.

6.2.5. Visualización de Resultados

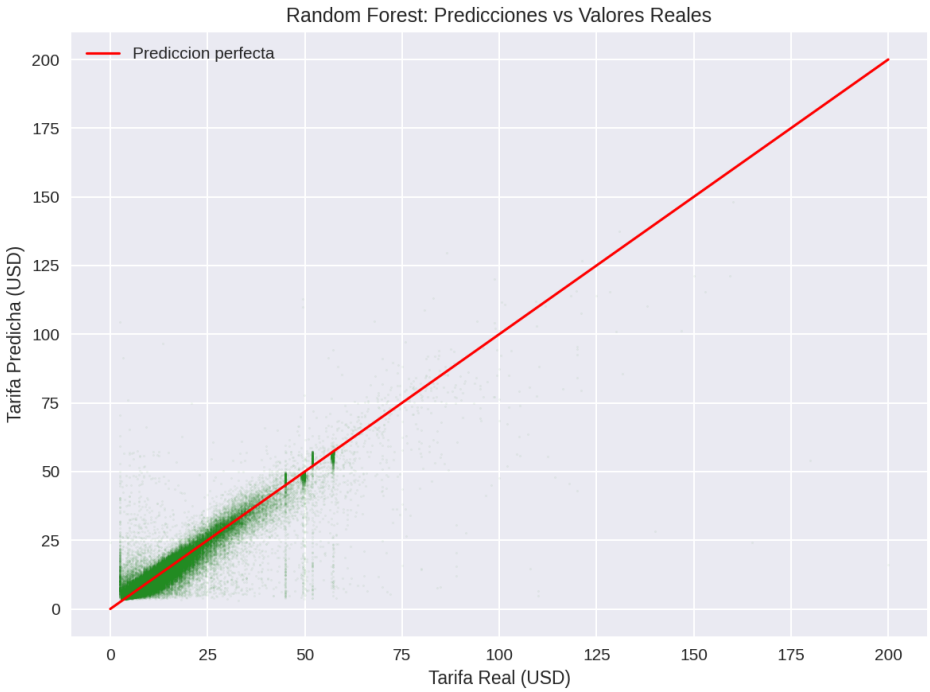

Figura 8: Random Forest: Predicciones vs Valores Reales, se ve que una mayor densidad de puntos sobre la diagonal ideal en comparación con el modelo lineal, especialmente en tarifas menores a $60.

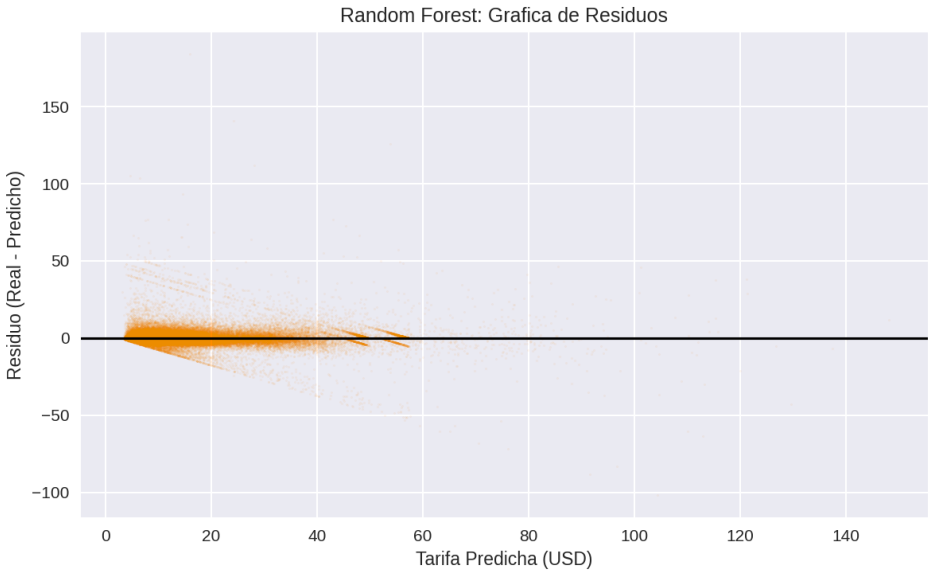

Figura 9: Random Forest: Gráfica de Residuos, aunque los errores están más centrados en cero, persisten desviaciones significativas en tarifas altas.

6.2.6. Análisis de Puntos de Alta Influencia

Se analizaron las 10 observaciones con mayor error absoluto en el conjunto de prueba, los errores máximos (hasta $184) corresponden a viajes con tarifas muy altas ($140–$200) pero distancias menores a 3 km, esto quiere decir que la existencia de tarifas fijas o recargos especiales no capturados por las variables actuales. Estos casos extremos representan menos del 0.01 % del dataset y no comprometen la validez general del modelo.

6.2.7. Limitaciones

- **Overfitting moderado:** La brecha de desempeño entre entrenamiento y prueba indica que el modelo memoriza parte del ruido, debido a que el crecimiento de los árboles no fue limitado (`max_depth=None`).
- **Costo computacional:** El tiempo de entrenamiento es significativamente superior al de la Regresión Lineal, requiriendo más de 5 minutos para el *grid search* con la submuestra.
- **Predicciones acotadas:** Al ser un modelo basado en árboles, no puede extrapolar valores fuera del rango visto en el entrenamiento, lo que limita su capacidad para predecir tarifas récord futuras.

6.3. Red Neuronal Densa (MLP)

6.3.1. Descripción del Modelo

Una Red Neuronal Densa (MLP) es un modelo de aprendizaje profundo compuesto por capas totalmente conectadas. Cada neurona recibe como entrada todas las salidas de la capa anterior, aplicando una función de activación no lineal para capturar relaciones complejas entre las variables.

Se eligió como tercer modelo por su capacidad de aproximar funciones no lineales arbitrarias, lo cual aborda directamente la heterocedasticidad detectada en la Regresión Lineal. A diferencia del Random Forest, el MLP sí requiere normalización de los datos, por lo que se aplicó `StandardScaler` sobre `X_train` y se transformó `X_test` con el mismo scaler ajustado.

6.3.2. Búsqueda de Hiperparámetros

Se evaluaron 6 arquitecturas distintas sobre una submuestra de 150,000 filas del conjunto de entrenamiento, con validación interna 80/20 y *Early Stopping* de 5 épocas de paciencia. La métrica de optimización fue el MAE.

Cuadro 11: Resultados de la búsqueda de hiperparámetros — MLP

Configuración	**Capas**	**Dropout**	**Val MAE**	**Val RMSE**
Shallow-NoDrop	[128, 64]	0.00	**1.8258**	**3.7584**
Medium-Drop10	[256, 128, 64]	0.10	9.8488	10.6258
Medium-Drop20	[256, 128, 64]	0.20	9.2379	10.1566
Deep-Drop20	[512, 256, 128, 64]	0.20	9.5519	10.6092
Deep4-Drop15	[256, 128, 64, 32]	0.15	11.0865	11.8749
Wide3-Drop20	[512, 256, 128]	0.20	9.2423	10.1138

La mejor configuración fue **Shallow-NoDrop**, con dos capas ocultas de 128 y 64 neuronas, sin dropout y *learning rate* de 0.001. Las arquitecturas más profundas no lograron converger adecuadamente en 30 épocas sobre la submuestra, obteniendo MAE significativamente más altos.

Cuadro 12: Mejores hiperparámetros encontrados — MLP

Hiperparámetro	**Valor óptimo**
Capas ocultas	[128, 64]
Activación	ReLU
Dropout	0.0
Learning rate	0.001
Batch size	1024
Optimizador	Adam

El modelo final fue entrenado sobre el conjunto completo de entrenamiento (771,815 filas) con *Early Stopping* de 8 épocas de paciencia y *ReduceLROnPlateau* con factor 0.5. El entrenamiento se detuvo en la época 39, restaurando los pesos de la época 31, en un tiempo total de 76.9 segundos.

6.3.3. Arquitectura del Modelo

Cuadro 13: Arquitectura del MLP final

Capa	**Salida**	**Parámetros**
Dense(128) + ReLU	(None, 128)	2,176
BatchNormalization	(None, 128)	512
Dense(64) + ReLU	(None, 64)	8,256
BatchNormalization	(None, 64)	256
Dense(1)	(None, 1)	65
Total		**11,265**

6.3.4. Métricas de Evaluación

Cuadro 14: Métricas de desempeño — MLP

Conjunto	MAE	RMSE	R^2
Train	1.6648	3.4948	0.8652
Test	1.6796	3.5336	0.8614

El modelo obtuvo un R^2 de 0.86 en el conjunto de prueba. La diferencia entre las métricas de train y test es mínima (MAE de \$0.015 y R^2 de 0.004), lo que confirma que no existe overfitting, a diferencia del Random Forest que mostró una brecha de 0.086 en R^2.

6.3.5. Visualización de Resultados

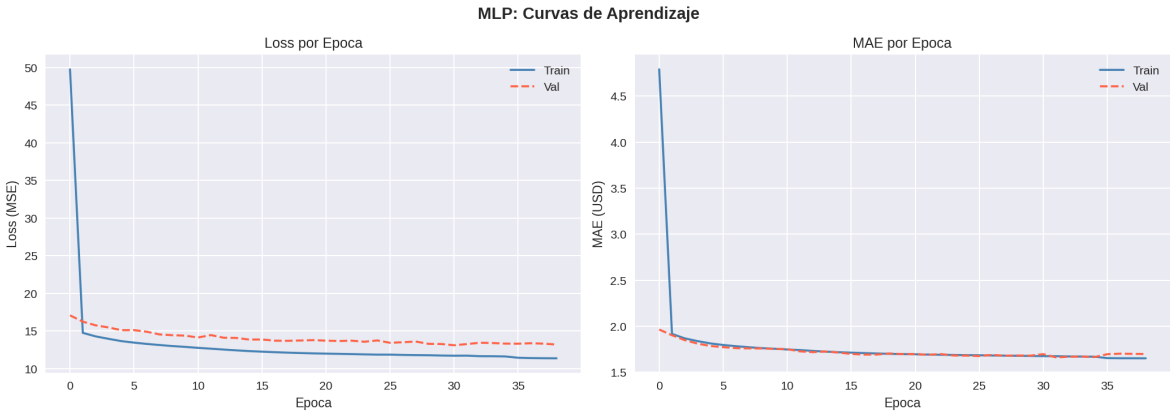

Figura 10: MLP: Curvas de aprendizaje. La convergencia entre train y validación confirma la ausencia de overfitting.

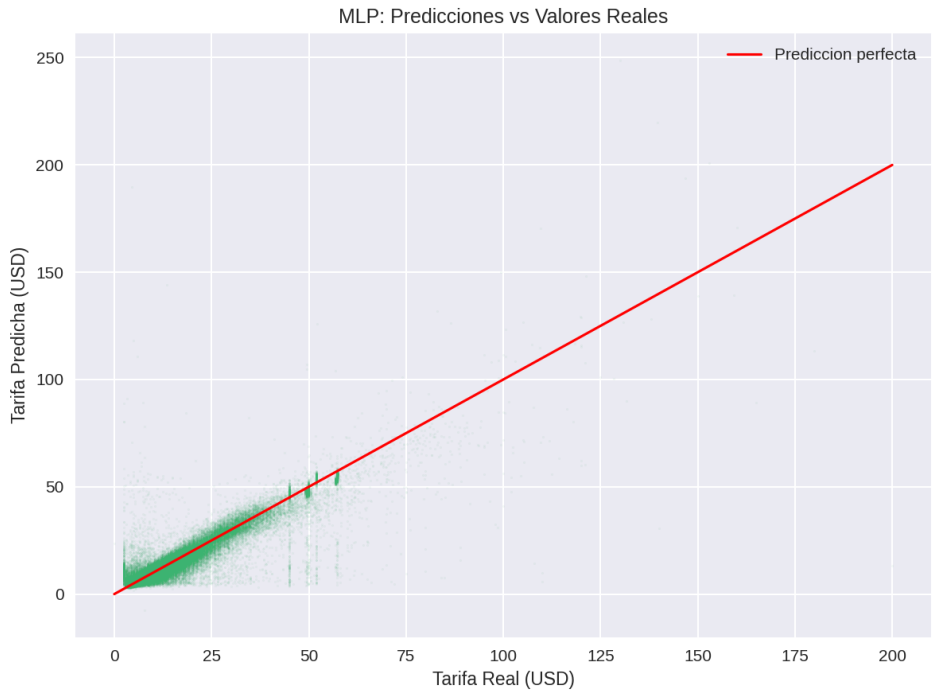

Figura 11: MLP: Predicciones vs Valores Reales. Alta densidad de puntos sobre la diagonal ideal, especialmente en tarifas menores a $60.

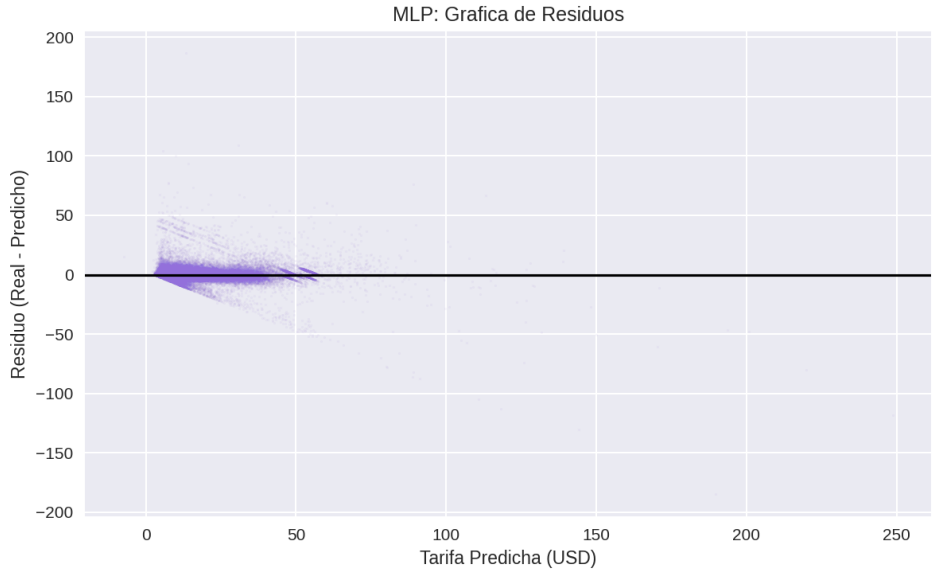

Figura 12: MLP: Gráfica de Residuos. Los errores están centrados en cero con menor dispersión que la Regresión Lineal, aunque persisten desviaciones en tarifas altas.

6.3.6. Análisis de Puntos de Alta Influencia

Se analizaron las 10 observaciones con mayor error absoluto en el conjunto de prueba:

Cuadro 15: Top 10 observaciones con mayor error absoluto — MLP

Distancia (km)	Tarifa Real ($)	Tarifa Predicha ($)	Error ($)	Aeropuerto
2.9238	200.00	13.29	186.71	Ninguno
0.3891	4.50	189.59	185.09	Ninguno
27.4087	13.50	144.08	130.58	Ninguno
53.0073	130.00	248.69	118.69	JFK (origen)
0.8792	5.00	118.29	113.29	Ninguno
0.0008	140.00	30.83	109.17	Ninguno
2.2872	6.00	110.83	104.83	Ninguno
0.0059	110.00	5.68	104.32	Ninguno
0.0036	110.00	9.97	100.03	Ninguno
3.8286	108.00	14.26	93.74	Ninguno

Los errores más grandes corresponden a dos patrones. Primero, viajes con distancias cercanas a cero pero tarifas superiores a $100, lo que indica tarifas fijas o recargos especiales no capturados por las variables del modelo. Segundo, viajes cortos con tarifas extremadamente bajas donde el modelo sobreestima significativamente, posiblemente registros con ruido residual tras la limpieza. Estos casos representan menos del 0.01 % del dataset y no comprometen la validez general del modelo.

6.3.7. Limitaciones

- **Costo computacional moderado:** El entrenamiento tomó 76.9 segundos en CPU, superior a la Regresión Lineal (0.11s) pero significativamente inferior al grid search del Random Forest (320.7s).
- **Requiere normalización:** A diferencia del Random Forest, el MLP es sensible a la escala de los datos y necesita preprocesamiento adicional.
- **Dificultad con tarifas altas:** Al igual que los modelos anteriores, persisten errores en viajes con tarifas superiores a $100 asociados a recargos especiales no capturados por las variables actuales.

7. Prueba de Usuario

Se implementó una función que recibe las coordenadas de origen y destino, la fecha, la hora y el número de pasajeros, calcula internamente la distancia Haversine y los flags de aeropuerto, y devuelve la predicción de los tres modelos entrenados.

Cuadro 16: Resultados de la prueba de usuario — tres escenarios

Escenario	**Distancia**	**Pasajeros**	**Reg. Lineal**	**Random Forest**	**MLP**
Viaje corto Manhattan	9.20 km	1	\$25.46	\$57.61	\$85.88
Viaje a JFK	21.77 km	2	\$55.98	\$56.13	\$57.24
Viaje nocturno	2.40 km	3	\$11.01	\$9.90	\$9.18

En el viaje al aeropuerto JFK los tres modelos convergen en aproximadamente \$56, lo cual es coherente con las tarifas reales hacia ese destino. En el viaje nocturno corto también coinciden alrededor de \$10. La mayor divergencia se observa en el primer escenario, donde la Regresión Lineal predice \$25.46 mientras que el MLP predice \$85.88, reflejando las diferencias en cómo cada modelo captura las relaciones no lineales entre distancia y tarifa.

8. Comparación de Resultados

La siguiente tabla resume el desempeño de los tres modelos entrenados sobre el mismo conjunto de datos, evaluados en el conjunto de prueba (192,954 registros):

Cuadro 17: Comparativa general de modelos

Modelo	**MAE Train**	**MAE Test**	**RMSE Test**	**R^2 Test**	**Overfitting**	**Tiempo (s**
Regresión Lineal	2.1444	2.1469	4.2267	0.8017	Ninguno	0.11
Random Forest	0.9196	1.6436	3.4233	0.8699	Moderado	350.8
MLP	1.6648	1.6796	3.5336	0.8614	Ninguno	308.1

El Random Forest obtiene el mejor MAE en test (\$1.64) y el mayor R^2 (0.87), pero presenta overfitting moderado con una brecha de 0.086 entre train y test en R^2, y requiere el mayor tiempo de entrenamiento. La Regresión Lineal es la más rápida (0.11s) y no presenta overfitting, pero su capacidad predictiva es inferior al no capturar relaciones no lineales entre las variables.

El MLP ofrece el mejor balance entre precisión y generalización: obtiene un MAE de \$1.68 y un R^2 de 0.86 en test, prácticamente idénticos a sus métricas de entrenamiento (diferencia de \$0.015 en MAE y 0.004 en R^2), confirmando la ausencia de overfitting. Su tiempo de entrenamiento (308.1s) es comparable al Random Forest pero con un modelo significativamente más simple (11,265 parámetros).

Por estas razones, el **MLP** es el modelo seleccionado como el más adecuado para este problema, ya que ofrece alta precisión, excelente generalización y un costo computacional razonable.

9. Conclusiones

El presente proyecto demostró que es posible construir un modelo predictivo de tarifas de taxi en Nueva York con un error promedio inferior a $2.00 por viaje, utilizando únicamente variables derivadas de las coordenadas geográficas y la fecha y hora del viaje.

La fase de limpieza y preparación de datos fue determinante para la calidad de los modelos. El dataset original contenía registros corruptos con coordenadas fuera de cualquier rango real, tarifas negativas y conteos de pasajeros imposibles. Tras aplicar los filtros definidos, el dataset quedó en 964,769 registros válidos de un millón inicial, lo que representa una pérdida del 3.5 % considerada aceptable.

La ingeniería de características demostró ser el factor más influyente en el desempeño de los modelos. La variable `distance_km` calculada mediante la Fórmula de Haversine dominó la predicción con un 83 % de importancia en el Random Forest, confirmando que la distancia es el principal determinante de la tarifa. Las variables temporales y los flags de aeropuerto aportaron información complementaria relevante, especialmente para viajes hacia Newark y JFK.

La comparación de los tres modelos reveló resultados claros. La Regresión Lineal estableció una línea base sólida con un R^2 de 0.80 y sin overfitting, pero su incapacidad para capturar relaciones no lineales limitó su precisión. El Random Forest mejoró el R^2 a 0.87 pero presentó overfitting moderado. El MLP logró el mejor balance, alcanzando un R^2 de 0.86 sin overfitting y con una diferencia mínima entre train y test, lo que lo convierte en el modelo más confiable para datos nuevos.

Los tres modelos coincidieron en identificar las mismas limitaciones: viajes con tarifas fijas o recargos especiales no capturados por las variables disponibles, como ciertos viajes al aeropuerto JFK o recargos nocturnos, generan los errores más altos independientemente del algoritmo utilizado. Incorporar variables adicionales como el tipo de tarifa o los recargos aplicados mejoraría significativamente la precisión en estos casos.